知源 · ZHIYUAN

# 企业知识大脑

私有化 · 多模态 · 国产化 · 可审计的 AI 原生知识基础设施

**产品白皮书 · Whitepaper v1.1**

面向对象：战略投资人 · 企业决策者

2026 年 4 月 · 修订 04-26

*本文件含前瞻性陈述，仅供受托评估；未经授权不得外传。*

# 执行摘要

知源（ZhiYuan）是一款面向大中型企业的 AI 原生知识大脑。它把分散在文档、合同、图纸、会议纪要、邮件和 IM 里的“沉默知识”变成可私有化部署、带来源引用、带权限与审计的问答系统。员工以自然语言提问，秒级拿到答案和原文出处。

当前企业知识管理正处在一个十年一遇的重塑窗口：大语言模型能够以对话方式组织知识，但 SaaS 形态的 AI 产品在中国金融、央企、政府、医疗等强监管行业天然无法被采用——数据主权和国产化适配成为这一波 AI 落地的第一道门槛。

我们用五个 Docker 容器的私有栈、八层推理的 Agentic RAG（含 L0 分级粗筛）、Agent 跨会话长期记忆、多模态 PDF v2（支持扫描件与图表）、三层权限与全量审计、Apache AGE 知识图谱、以及 MCP 开放协议——把私有化 + 国产化 + 先进 AI 能力三个在业界通常对立的要素，一次性合并在同一产品里。

> *30 分钟私有化上线 · 数据零外传 · 国产大模型原生适配 · 替代 Confluence × Glean × Notion AI 工具链。L0 分级粗筛实测召回 +2.7pp（GM-LIFTGATE32 评测集），ADR-32 已 Accepted。*

## 核心数据

| 指标 | 数值 | 说明 |
|---|---|---|
| 架构决策（ADR） | 32 条 | 永不覆盖的决策记录，全部可回溯 |
| 冻结行为契约（OpenSpec） | 21 个 | 每一个模块都有锁定的行为规范 |
| 功能模块 | 11 个 | Overview/Spaces/Ingest/QA/Agent/Governance/IAM/Eval/Notebooks/MCP/Assets |
| 私有化部署时间 | 30 分钟 | Docker Compose 一键起栈 |
| 降级能力 | 7 层 | Java / VLM / Reranker / AGE / SMB / 调度 / 鉴权 全部可降级 |

# 1. 市场机会

## 1.1 AI 重塑企业知识管理的三年窗口期

企业知识管理是一个被严重低估的万亿级赛道。Gartner 2025 年估计，全球企业每年因“找不到已有知识而重复劳动”造成的损失占员工工时的 19%~25%。72% 的企业知识沉淀在文档、邮件、IM 里从未被检索过。

大模型的出现第一次让“自然语言问答 + 精准原文定位”成为现实。但这条赛道面临的三大挑战决定了未来三年的格局：

- 数据主权：SaaS 形态 AI 产品在强监管行业无法落地（金融、央企、政府、医疗、军工）；
- 国产化适配：国产大模型快速崛起（通义、DeepSeek、Qwen-VL），企业需要国产替代 + 国际化双栈；
- 工程化门槛：让 LLM 在企业级场景稳定输出，需要八层以上的推理管线、完整的权限与审计、多模态处理能力——绝大多数创业公司只做到了其中一层。

> *结论：AI 原生 + 私有化 + 国产化 = 未来三年中国企业知识市场最确定的交集。*

## 1.2 竞争格局

| 竞品 | 形态 | 数据主权 | 国产化 | 多模态 | 知识图谱 | MCP |
|---|---|---|---|---|---|---|
| Confluence Wiki | SaaS/私有 | 部分 | 否 | 否 | 否 | 否 |
| Glean | SaaS | 否 | 否 | 有限 | 有限 | 否 |
| Notion AI | SaaS | 否 | 否 | 有限 | 否 | 否 |
| 飞书知识问答 | SaaS | 否 | 是 | 有限 | 否 | 否 |
| 知源 ZhiYuan | 私有化 | 完全 | 原生 | 完整（VLM） | AGE | 原生 |

在“私有化 × 国产化 × 多模态 × 知识图谱 × MCP 协议”五个维度同时满足的产品，目前市场上不存在第二个。这构成了知源的结构性护城河。

## 1.3 目标市场

### 优先行业（P0）

- 金融：银行、保险、券商——强监管，数据不出域是硬性合规要求；
- 央国企：能源、交通、电信——国产化替代 + 本地化部署是采购规范；
- 政府与公共事业：档案局、法院、税务——数据主权 + 合规审计刚需；
- 医疗：医院、药企——临床指南 + 病例知识库 + 多模态（CT / 病理图片）。

### 扩展行业（P1）

- 制造业：设备手册 + 工单 + 图纸的图文混排场景；
- 法律 / 咨询：合同、判例、项目交付物的专家网络场景；
- 研发密集型企业：芯片、生物、材料——内部研报 + 专利 + 实验记录。

# 2. 产品

## 2.1 一句话定义

> *知源是一套可私有化部署的 AI 知识大脑。上传文档、一问即答、带原文引用、带权限控制、带全量审计。*

## 2.2 八大差异化能力

### 01 · 数据主权 · 五容器私有栈

全部组件容器化：BookStack（Wiki UI）+ MySQL 8（权限与治理）+ pgvector pg16（向量真相源）+ Apache AGE（知识图谱）+ QA Service（Node 22 + Express 5）。客户机房一台服务器，Docker Compose 一键部署，30 分钟上线。数据、向量、对话、审计日志全部留在内网，任何外部接口均可关闭。

### 02 · 国产大模型原生适配

LLM 层：硅基流动 Qwen-VL-72B / 通义千问 / DeepSeek / Anthropic Claude / OpenAI 五路均可切换；Embedding 层：Qwen Embedding 默认。env 变量一行配置，不动代码。

### 03 · 多模态问答（PDF Pipeline v2）

行业头部的 RAG 产品大多只能处理纯文本 PDF。知源内置视觉大模型（Qwen2.5-VL-72B），扫描合同、产品截图、架构图、财报 PPT 里的图表都能被问答命中——这在制造、法务、医疗行业是硬刚需。引擎：@opendataloader/pdf（Java CLI 结构化解析）+ VLM caption + 图片落档 + 完整降级链。

### 04 · 知识图谱自生长（Apache AGE）

每次问答 fire-and-forget 写入 CITED / CO_CITED 边，自动绘制“谁在引用谁”的知识地图。节点：Asset / Source / Space / Tag / Question；边：CONTAINS / SCOPES / HAS_TAG / CITED / CO_CITED。自动识别权威文档、孤岛文档、重复文档，帮知识库管理员做治理决策。

### 05 · 一次接入存量文档

FileSourceAdapter 抽象层已实现 SMB，预留 S3 / WebDAV / SFTP 扩展位。凭据 AES-256-GCM 加密；node-cron 调度增量扫描；同源串行锁；离线软删。客户 20 万份老文档指到内网 NAS，当天可问。

### 06 · MCP 开放协议（新一代 Agent 入口）

独立 mcp-service 进程，stdio + streamable HTTP 双 transport。Cursor / Claude Desktop / 通义灵码等 Agent 工具链即插即用，企业知识库瞬间变成所有 AI 助手的“共享记忆体”。使用最小权限 token，读写分离。

### 07 · 工程执行力 · 四阶段 AI 协作流水线

自研的 Superpowers + OpenSpec 四阶段工作流（Explore → Lock → Execute → Archive）+ 永不覆盖的 ADR + 冻结 Spec 三件套，保证交付可复盘、可审计、不依赖单一工程师。32 条 ADR + 21 个冻结 Spec + 21 个归档 change 全部可追溯。

### 08 · Agent 长期记忆 + L0/L1 分级摘要

ingest 阶段为每个 chunk 自动生成 L0 一句话摘要 + L1 结构化概览（Qwen2.5-72B + JSON 强制输出），落到 chunk_abstract 表。RAG 在向量精检索之前先用 L0 做 ANN 粗筛收窄 candidate asset，让 rerank / gradeDocs 在更纯净的候选集上工作。GM-LIFTGATE32 评测集实测召回率 0.973 → 1.000（+2.7pp），原本未命中的复杂题目全部命中。同时 OpenViking 容器作为对照实验提供 Agent 跨会话长期记忆能力（默认 off，私有化客户按需启用）。来源：ADR-31 / ADR-32。

# 3. 技术架构

## 3.1 四层架构

自上而下：客户端层 → 边缘层 → 核心服务层 → 数据与外部 LLM 层。

### 客户端层

- Web 控制台：React 19 + Vite 8 + Tailwind 4 + TanStack Query + React Router 7；11 个业务模块（Overview / Spaces / Ingest / QA / Agent / Governance / IAM / Eval / Notebooks / MCP / Assets）；
- 外部 Agent / IDE：通过 MCP Service 接入，支持 Cursor、Claude Desktop、自研 Agent；
- 第三方系统：企业 IM（飞书 / 钉钉）、OA、客服机器人通过 REST 或 MCP 接入。

### 核心服务层（**qa-service · Node 22 + Express 5**）

- Agent 编排：POST /api/agent/dispatch（SSE），LLM 结构化意图识别 + 关键字 fallback，4 个 Agent（知识问答 / 数据治理 / 结构化查询 / 元数据运维）；
- Agentic RAG：八层推理（L0 粗筛 → 自适应 top-K → 混合召回 → rerank → gradeDocs → rewriteQuestion → generateAnswer → short-circuit 兜底）；
- 统一 Ingest：按扩展名路由到 PDF v2 / mammoth / officeparser / 单图 VLM / 平文本，所有上传入口共用；
- 统一鉴权：JWT 双栈（JWKS / HS256）+ Permissions V2（角色 / 用户 / 团队 × 允许 / 拒绝 × 时效 TTL × 资源双维度）+ 全量审计；
- 治理模块：tags / duplicates / quality / audit-log 四个子路由与业务解耦。

### 数据层

- BookStack（MySQL 8）：Wiki UI + Markdown 渲染 + 原生权限；
- pgvector pg16：向量检索真相源，Hybrid Search 支持 BM25 + 向量并行召回；
- Apache AGE（独立 PG 实例）：知识图谱 sidecar，可独立下架、独立回退；
- FileSourceAdapter：SMB / S3 / WebDAV / SFTP 多协议适配。

### 外部 **LLM / Embedding**

- LLM：Anthropic Claude / OpenAI / 硅基流动（通义 + DeepSeek + Qwen-VL）；
- Embedding：Qwen Embedding（默认）或 OpenAI text-embedding-3。

## 3.2 Agentic RAG 八层推理管线

| 步骤 | 功能 | 降级策略 |
|---|---|---|
| 0. L0 粗筛（新增） | L0 摘要 ANN 检索 candidate asset_ids（ADR-32） | 表空 / 失败时无缝回退原路径 |
| 1. retrieveInitial | pgvector 召回 + 自适应 top-K（5 / 10 / 15） | Hybrid 失败回退纯向 |

| | | 量 |
|---|---|---|
| 2. rerank | Cross-encoder 精排 | Reranker 失败跳过 |
| 3. gradeDocs | LLM 评分（function-call 结构化输出） | 失败保留 Top 2 兜底 |
| 4. rewriteQuestion | 召回不足（<3）自动重写 | 关键字 fallback |
| 5. generateAnswer | 流式生成 + 对话历史 | 空流守护主动抛错 |
| 6. short-circuit（D-007） | top-1 过低直接兜底，不毒化 LLM | Notebook 场景自动豁免 |
| 7. 引用写入图谱 | fire-and-forget CITED 边 | AGE 离线时 no-op |

## 3.3 企业级安全

- 数据主权：五容器私有栈，所有外部网络可关闭；
- 凭据管理：AES-256-GCM 加密，API 返回前自动打码；
- 鉴权：JWT + JWKS 或 HS256；生产启动 fail-fast，缺密钥直接退出；
- 审计：业务审计 audit_log + ACL 专用 acl_rule_audit（结构化 before / after diff）；
- 可观测：每个 ingest / RAG 步骤都 emit 结构化事件，F12 可直接看全程推理轨迹。

# 4. 进度与交付

## 4.1 开发里程碑（2026-04 snapshot）

| 日期 | 交付 | 规模 |
|---|---|---|
| 2026-04-21 | RAG + unified-auth + governance + ingest UI 底座 | 15 条 ADR |
| 2026-04-22 | Permissions V2 选型 + 代码落地 | +1 条 ADR |
| 2026-04-23 | permissions-v2 lock + execute + archive；24 条 bug 5 批清完；核心检索 BUG-01 根治 | +11 条 ADR |
| 2026-04-26 | OpenViking sidecar 实验（ADR-31）+ ingest-l0-abstract（ADR-32 · 召回 +2.7pp） | +5 条 ADR |
| 合计 | 32 ADR + 21 冻结 Spec + 21 归档 change | 4 天 snapshot 全可回 |

## 4.2 已交付模块

- 知识问答（Agentic RAG + Hybrid Search + Reranker）
- 统一 Ingest 管线（PDF v2 + VLM + 6 种格式 + 图片落档）
- Permissions V2（三主体 × 允许/拒绝 × TTL × 双维资源 × Notebook 共享 × 全量审计）
- Agent 编排（4 个 Agent，意图识别，向后兼容）
- File Source Integration（SMB 已上线，S3 / WebDAV / SFTP 预留接口位）
- Knowledge Graph（Apache AGE sidecar + DetailGraph 前端）
- Governance 模块（tags / duplicates / quality / audit-log）
- MCP Service（stdio + HTTP 双通道）
- L0/L1 分级摘要 + RAG L0 粗筛（ADR-32 · 召回 +2.7pp）
- Agent 跨会话长期记忆（OpenViking sidecar · ADR-31 实验）
- Eval 框架（Dataset → Run → Metrics）
- Web 控制台（11 个模块，React 19）

## 4.3 工程质量

- TypeScript 严格模式：qa-service tsc --noEmit EXIT 0；web 仅 5 处 pre-existing React 19 类型遗留；
- 单测覆盖：qa-service 207/209 通过，新增 change 0 fail；
- 可维护性：ADR 永不覆盖 + OpenSpec 锁定契约 + Progress Snapshot 按日期落盘，换人换 AI 上下文都能续接。

# 5. 商业模式与 Go-to-Market

## 5.1 收入模型（三条线）

### A · 私有化授权（主收入）

按客户企业授权一次性收取许可费 + 按年续订维护费。定价锚点：公司规模、节点数、存储容量、并发用户。目标：金融、央国企、政府年单 80 万 ~ 500 万 RMB。

### B · SaaS 订阅（中小客户漏斗）

多租户版本，按坐席 / 月计费。定价锚点：99 元 / 坐席 / 月起。目标：500 人以下公司、律所、咨询团队作为试点漏斗，验证产品后迁移私有化。

### C · 行业解决方案 + 定制化

头部客户的定制接入（行业知识图谱、合规模板、深度集成 OA / IM）按人天计费或固定包。定价锚点：单项目 100 万 ~ 300 万 RMB。打造标杆客户 + 产品行业化沉淀。

## 5.2 客户获取策略

### 渠道 1 · 生态驱动（MCP 协议）

借 MCP 生态崛起红利，把知源作为 Cursor / Claude Desktop 的企业级“记忆体”推广。开发者试用 → 带回公司 → 撬动企业采购。这是 Glean / Notion 不具备的新入口。

### 渠道 2 · 合规集成商

与金融云、政务云 ISV（华为云 / 阿里云 / 浪潮 / 用友）联合方案，以“国产化 AI 知识管理”进政府、央企、金融招标目录。

### 渠道 3 · 行业标杆

每个优先行业拿下 1~2 个标杆客户（例：某股份制银行、某头部律所），产出行业白皮书，形成口碑裂变。

## 5.3 单位经济（初步模型）

| 指标 | 假设值 | 备注 |
|---|---|---|
| 平均合同价值 ACV（私有化） | 150 万 RMB / 年 | 中型企业首年 |
| 获客成本 CAC | 30 万 RMB | 销售 + SA + 定制接入 |
| LTV（5 年续订） | 600 万 RMB | 按 80% 续约率估 |
| LTV/CAC | 20× | 优于 SaaS 行业基准（3×） |
| 毛利率 | 75%+ | 私有化低边际成本，主要是人力 |

## 5.4 三年目标

- Y1：3~5 家标杆客户（金融 + 央企 + 政府各 1~2 家），ARR 500 万~1000 万 RMB；
- Y2：30~50 家企业客户，打造 2 个行业解决方案，ARR 5000 万~8000 万 RMB；
- Y3：200+ 企业客户，行业 Top 3 私有化知识平台品牌，ARR 2~3 亿 RMB；同步推出 SaaS 漏斗版本。

# 6. 产品路线图

| 季度 | 主题 | 关键交付 |
| --- | --- | --- |
| 2026 Q2 | 企业就绪 | OIDC / Keycloak 接入、SSO；接入 S3 / WebDAV；行业 prompt 模板库 |
| 2026 Q3 | 智能体扩展 | Agent 编排可视化编辑器；第三方 MCP 工具市场；审批 / 工单类 Agent |
| 2026 Q4 | 企业图谱 | AGE 节点扩展到 People / Project / Customer；专家网络与项目配对 |
| 2027 H1 | 多语言 + 海外 | 英 / 日 / 韩 多语 UI；GDPR / HIPAA 合规白皮书 |
| 2027 H2 | 企业 AI 工作流 | 文档自动撰写、合同智能比对、会议智能纪要闭环 |

# 7. 风险与对策

| 风险 | 对策 |
| --- | --- |
| 国产大模型能力参差 | LLM 层抽象化，五路可切；业务不绑定单一模型 |
| 竞品大厂下场（飞书 / 钉钉 AI） | 私有化 + 国产化 + 图谱 + MCP 四重壁垒；行业深度非大厂强项 |
| 客户决策周期长 | MCP 开发者漏斗 + 集成商渠道 + 标杆客户口碑，三路并进 |
| 技术人才稀缺 | 四阶段 AI 协作工作流 + ADR / Spec 三件套，弱化对单一工程师依赖 |

# 8. 接触与下一步

本白皮书面向战略投资人与企业决策者。如有兴趣深入了解：

- 安排 30 分钟产品演示（包含真实私有化部署、多模态问答、知识图谱演示）；
- 参与首批试点计划（享定制接入 + 专属 SA 支持 + 12 个月免费升级）；
- 获取技术架构深度资料（代码示例、ADR 全集、性能测试报告）。

本文档中所有前瞻性陈述均为商业评估目的，不构成投资建议或服务承诺。

© 2026 知源 · ZhiYuan. All rights reserved.